

线性空间

- 设 A, B 是线性空间 V 的线性子空间, 则
 - 称 $A+B \triangleq \{x+y \mid x \in A \wedge y \in B\}$ 为 A 和 B 的和
 - 称 $A \cap B \triangleq \{x \mid x \in A \wedge x \in B\}$ 为 A 和 B 的交
 - 若 $A+B=V \wedge A \cap B = \{0\}$, 则称 V 是 A 和 B 的直接求和, 简称直和, 记作
$$V = A \oplus B$$
- 定理: $A+B$ 和 $A \cap B$ 是 V 的线性子空间
- 推论: $A+B$ 是 V 中包含 A 和 B 的最小线性子空间, $A \cap B$ 是 V 中既属于 A 又属于 B 的最大线性子空间

内积空间

- 定义: 设 U 是数域 $K(\mathbb{R} \text{ or } \mathbb{C})$ 上的线性空间, 若 $\forall x, y \in U$, 存在唯一的数 $\langle x, y \rangle \in K$, 满足下列三条内积公理:

- 正定性: $\langle \alpha, \alpha \rangle \geq 0, \langle \alpha, \alpha \rangle = 0 \Leftrightarrow \alpha = 0$
- 对第一变元线性: $\langle k_1\alpha + k_2\beta, \gamma \rangle = k_1\langle \alpha, \gamma \rangle + k_2\langle \beta, \gamma \rangle$
- 共轭对称性: $\langle \alpha, \beta \rangle = \overline{\langle \beta, \alpha \rangle}$

则称 $\langle \xi, \eta \rangle$ 为 ξ, η 的内积, U 为内积空间。

- 推论: $\langle \alpha, k_1\beta + k_2\gamma \rangle = \overline{k_1}\langle \alpha, \beta \rangle + \overline{k_2}\langle \alpha, \gamma \rangle$
- 性质:
 - 内积的连续性
 - 内积空间的完备性: 内积空间 V 中的任意柯西序列收敛于 V 内。
- 典范内积: n 阶复向量 x, y 之间的内积 $\langle \alpha, \beta \rangle \triangleq \alpha^H \beta = \sum_{i=1}^n \overline{x_i} y_i$, 其中 $A^H \triangleq \overline{A}^T$
- 函数向量内积: $\langle \alpha(t), \beta(t) \rangle \triangleq \int_a^b \alpha^H(t) \beta(t) dt$

赋范空间

- 定义: 在内积空间 U 中, 若令 $\|\alpha\| = \sqrt{\langle \alpha, \alpha \rangle}$, 即 $\|\alpha\|^2 = \langle \alpha, \alpha \rangle$, 则其满足范数公理:
 - $\|\alpha\| \geq 0, \|\alpha\| = 0 \Leftrightarrow \alpha = 0$
 - $\|k\alpha\| = |k| \cdot \|\alpha\|$

- $\|\alpha + \beta\| \leq \|\alpha\| + \|\beta\|$

称 U 是按内积导出的赋范线性空间。进一步可由范数导出距离 $\rho(\alpha, \beta) = \|\alpha - \beta\|$, 则

U 也是距离空间

- 常见向量范数:

- 0 范数: $\|\alpha\|_0 \triangleq$ 非零元素个数

- 无穷范数、极大范数: $\|\alpha\|_\infty \triangleq \max\{|x_i|\}$

- p 范数: $\|\alpha\|_p = (\sum_{i=1}^n \|x_i\|^p)^{1/p}, p \geq 1$

- 函数向量范数: $\|\alpha(t)\| \triangleq (\int_a^b \alpha^H(t)\alpha(t)dt)^{1/2}$

- 2 范数 $\|\cdot\|_2$ 是酉不变的: $\|U\alpha\|_2 = \|\alpha\|_2$, 其中 U 是正交矩阵

Hilbert 空间

定义: 完备的赋范线性空间称为 Banach 空间

定义: 完备的内积空间 U 称为 Hilbert 空间, 记作 H

矩阵

- 向量化: 令 $m \times n$ 复矩阵 $A = [\alpha_1 \cdots \alpha_n]$, $vec(A) \triangleq [\alpha_1^T \cdots \alpha_n^T]^T$

- 内积: $\langle A, B \rangle: \mathbb{C}^{m \times n} \times \mathbb{C}^{m \times n} \rightarrow \mathbb{C}$, $\langle A, B \rangle \triangleq \langle vec(A), vec(B) \rangle = \sum_{i=1}^n \alpha_i^H \beta_i = tr(A^H B)$

- 范数: K 是一个数域, $K^{m \times n}$ 是 $m \times n$ 矩阵集合, 则矩阵的范数 $\|A\|$ 除了要满足范数公理外, 还需满足:

- $\|AB\| \leq \|A\| \|B\|$

- 诱导范数、算子范数: $\|A\| \triangleq \max\{\|Ax\|: x \in K^n, \|x\|=1\} = \max\{\frac{\|Ax\|}{\|x\|}: x \in K^n, x \neq 0\}$

- 1 范数、绝对列和范数: $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$

- 无穷范数、绝对行和范数: $\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$

- 2 范数、谱范数: $\|A\|_{spec} = \|A\|_2 = \sigma_1$ (最大奇异值)

■ 1 范数证明:

$$\|Ax\|_1 = \sum_{i=1}^m \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{i=1}^m \sum_{j=1}^n |a_{ij}| |x_j| = \sum_{j=1}^n |x_j| \sum_{i=1}^m |a_{ij}| \leq \left(\max_j \sum_{i=1}^m |a_{ij}| \right) \sum_{j=1}^n |x_j|$$

$$\therefore \|A\|_1 = \max_{x \neq 0} \frac{\|Ax\|_1}{\|x\|_1} \leq \max_j \sum_{i=1}^m |a_{ij}|$$

又取 k 使 $\sum_{i=1}^m |a_{ik}| = \max_j \sum_{i=1}^m |a_{ij}|$, 取 $x_0 = e_k = (0, \dots, 0, 1, 0, \dots, 0)^T$

则有 $\|A\|_1 = \max_{x \neq 0} \frac{\|Ax\|_1}{\|x\|_1} \geq \|Ax_0\|_1 = \sum_{i=1}^m |a_{ik}| = \max_j \sum_{i=1}^m |a_{ij}|$, 证毕。

无穷范数证明:

$$\|Ax\|_\infty = \max_i \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_i \sum_{j=1}^n |a_{ij}| |x_j| \leq \max_i \sum_{j=1}^n |a_{ij}| \max_j |x_j|$$

$$\therefore \|A\|_\infty = \max_{x \neq 0} \frac{\|Ax\|_\infty}{\|x\|_\infty} \leq \max_i \sum_{j=1}^n |a_{ij}|$$

又取 k 使 $\sum_{j=1}^n |a_{kj}| = \max_i \sum_{j=1}^n |a_{ij}|$, 取 $x_0 = (\text{sgn}(a_{k1}), \dots, \text{sgn}(a_{kn}))^T$

则有 $\|A\|_\infty = \max_{x \neq 0} \frac{\|Ax\|_\infty}{\|x\|_\infty} \geq \|Ax_0\|_\infty = \sum_{j=1}^n |a_{kj}| = \max_i \sum_{j=1}^n |a_{ij}|$, 证毕。

- 元素形式的 p 范数: $\|A\|_p \triangleq \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^p \right)^{1/p} = \|\text{vec}(A)\|_p$

伪逆矩阵

- 定义: 对 $A \in \mathbb{C}^{m \times n}$, 满足 $LA = E$ 但不满足 $AL = E$ 时, L 称为左逆矩阵; 满足 $AR = E$ 但不满足 $RA = E$ 时, R 称为右逆矩阵。

■ A 列满秩时, $L = (A^H A)^{-1} A^H$ 且唯一, 称为左伪逆矩阵

■ A 行满秩时, $R = A^H (A A^H)^{-1}$ 且唯一, 称为右伪逆矩阵

Moore-penrose 逆矩阵

- 定义: 设 $A \in \mathbb{C}^{m \times n}$, 若 $\exists G \in \mathbb{C}^{n \times m}$, 满足:

■ $AGA = A$

- $GAG = G$
- $(AG)^H = AG$
- $(GA)^H = GA$

称 G 是 A 的 M-P 广义逆, 记作 A^\dagger

- 性质:
 - 唯一性
 - $A^{H\dagger} = A^{\dagger H}$
 - $(A^\dagger)^\dagger = A$
 - $(cA)^\dagger = \frac{1}{c} A^\dagger$
 - $O_{m \times n}^\dagger = O_{n \times m}$
 - 若 $A = BC$, B 列满秩, C 行满秩, 则有 $A^\dagger = (BC)^\dagger = C^H (CC^H)^{-1} (B^H B)^{-1} B^H$
- 计算:
 - 矩阵的满秩分解: A 可以分解为 $A = F_{m \times r} G_{r \times n}$, 将 A 化为简化的阶梯型, 取主元列对应的原矩阵的列构成 F , 主元行构成 G 。

向量化与矩阵化

- 向量化: 矩阵 $A \in \mathbb{R}^{m \times n}$ 的向量化是一个线性变换, 将矩阵 A 按列堆栈排列成 $mn \times 1$ 矩阵, 记为 $\text{vec}(A)$; 按行堆栈排列成 $1 \times mn$ 矩阵, 记为 $\text{rvec}(A)$
- 存在唯一 $mn \times mn$ 交换阵满足 $K_{mn} \text{vec}(A) = \text{vec}(A^T)$
- 矩阵化

*稀疏表示与压缩感知

矩阵分解

Cholesky 分解:

- 定义: 任意一个正定矩阵 A 都可以分解为 $A = KK^T$, 其中 K 是对角线元素都大于 0 的上三角矩阵

- 计算：待定系数法，通过一定顺序可得递推式 $k_{ij} = \begin{cases} \sqrt{a_{ij} - \sum_{r=j+1}^n k_{jr}^2}, j=i \\ \frac{1}{k_{jj}} \left(a_{ji} - \sum_{r=j+1}^n k_{jr} k_{ir} \right), j>i \\ 0, j<i \end{cases}$

奇异值分解：

- 奇异值： $A \in \mathbb{C}_r^{m \times n}$ ， $A^T A$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > \lambda_{r+1} = \dots = \lambda_n = 0$ ，则称

$\sigma_i = \sqrt{\lambda_i}$ 为 A 的奇异值。

- $A^T A$ 或 AA^T 产生的非零奇异值相同，零奇异值个数不同：

$$A^T A \alpha = \lambda \alpha, AA^T (A \alpha) = \lambda (A \alpha)$$

- 奇异值分解 (SVD)： $A \in \mathbb{R}_r^{m \times n}$ ，则有 $A = USV^T$ ，其中 U 是 m 阶正交阵，V 是 n 阶正

交阵， $S_{m \times n} = \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix}$ ， $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ ，且 V 是 $A^T A$ 特征值分解中的 P，U 是

AA^T 特征值分解中的 P

- 民间简约形式： $A = U_{m \times r} \Sigma_r V_{n \times r}^T$ ，U、V 分别是 AA^T 、 $A^T A$ 的非零特征值对应的特征向量形成的矩阵。且 $U_{m \times r} = A_{m \times n} V_{n \times r} \Sigma^{-1}$ 。

- 定理证明（不完善）：

对 $A^T A$ 特征值分解： $V^T A^T A V = \Lambda = \begin{pmatrix} \Sigma^2 & 0 \\ 0 & 0 \end{pmatrix}$ ，由奇异值的定义，后一个等号成立

立

令 $V = (V_1, V_2)$ ， $V_1 : n \times r$ ， $V_2 : n \times (n-r)$

$$\text{代入得 } V^T A^T A V = \begin{pmatrix} V_1^T A^T A V_1 & V_1^T A^T A V_2 \\ V_2^T A^T A V_1 & V_2^T A^T A V_2 \end{pmatrix}$$

可以验证分块矩阵维数相同，比较得 $V_1^T A^T A V_1 = \Sigma^2$

左右各乘 Σ^{-1} ，即 $(AV_1 \Sigma^{-1})^T (AV_1 \Sigma^{-1}) = I$

令 $U_1 = AV_1 \Sigma^{-1}$ ，即 $U_1^T U_1 = I$

令 $U = (U_1, U_2)$ ， $U_2 : m \times (m-r)$

$$\text{则 } USV^T = (U_1, U_2) \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} V_1^T \\ V_2^T \end{pmatrix} = U_1 \Sigma V_1^T = AV \Sigma^{-1} \Sigma V_1^T = \dots A$$

其中 U_2 可由下述方法求得: $U_1^T x = 0$

- SVD 分解求广义逆:

$$A = USV^T = U \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix}_{m \times n} V^T, \text{ 则 } A^\dagger = VS^\dagger U^T = V \begin{pmatrix} \Sigma^{-1} & 0 \\ 0 & 0 \end{pmatrix}_{n \times m} U^T$$

最小二乘问题:

- 定义: 求 x , 使 $\|Ax - b\|_2 = \min \{\|Av - b\|_2, v \in \mathbb{R}^n\}$, 所有满足条件的 x 的集合记为 X_{LS} ,

最小范数解 x_{LS} 满足 $\|x_{LS}\|_2 = \min \{\|x\|_2, x \in X_{LS}\}$

- $x \in X_{LS} \Leftrightarrow A^T Ax = A^T b$

- 解的形式:

■ 一般解 $x = A^\dagger b + (I - A^\dagger A)z, z \in \mathbb{R}^n$

■ 最小范数解: $x_{LS} = A^\dagger b$

- 求解方法: A 列满秩, 即 $r(A) = n$ 时, 称为满秩最小二乘问题, 有唯一解。 $r(A) < n$ 时, 称为亏秩最小二乘问题, 有无穷解, 这时一般要求最小范数解。

■ $r(A) = n$ 时, Cholesky 分解: $A^T A = CC^T$, 解 $Cy = A^T b, C^T x = y$

■ $r(A) = n$ 时, QR 分解: $A = Q \begin{pmatrix} R \\ 0 \end{pmatrix} = Q_1 R$, 解 $Rx = Q_1^T b$

■ $r(A) = n$ 时, SVD 分解: $A = U \begin{pmatrix} \Sigma_n \\ 0 \end{pmatrix} V^T$, 于是 $A^\dagger = VS^\dagger U^T = V(\Sigma^{-1}, 0)U^T$

$$x = A^\dagger b = V(\Sigma^{-1}, 0)U^T b = \sum_{i=1}^n \frac{u_i^T b}{\sigma_i} v_i$$

■ $r(A) < n$ 时, SVD 分解: $A = U \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix} V^T$ 则可以直接得到最小范数解或一般解

$$x_{LS} = A^\dagger b = V \begin{pmatrix} \Sigma^{-1} & 0 \\ 0 & 0 \end{pmatrix} U^T b = \sum_{i=1}^r \frac{u_i^T b}{\sigma_i} v_i$$

函数矩阵：若矩阵 A 的元素 a_{ij} 均为实变量 t 的函数，即 $A(t) = (a_{ij}(t))_{m \times n}$

- 导数：若矩阵 A 中每个元素在 $t = t_0$ 处可导，则 A 在 t_0 处可导，记为 $\frac{dA(t)}{dt}$

- 性质：

- $A(t), B(t)$ 可导，则 $\frac{d}{dt}(A(t) \pm B(t)) = \frac{dA(t)}{dt} \pm \frac{dB(t)}{dt}$

- $\varphi(t)$ 是可导实值函数， $A(t)$ 可导，则 $\frac{d}{dt}(\varphi(t)A(t)) = \frac{d\varphi(t)}{dt}A(t) + \varphi(t)\frac{dA(t)}{dt}$

- $A(t), B(t)$ 可导可乘，则 $\frac{d}{dt}(A(t)B(t)) = \frac{dA(t)}{dt}B(t) + A(t)\frac{dB(t)}{dt}$

- $A(t)$ 可导可逆，则 $\frac{dA^{-1}(t)}{dt} = -A^{-1}\frac{dA(t)}{dt}A^{-1}$

- 链式法则

- $\frac{d}{dt}(trA) = tr\frac{dA}{dt}$

- 函数关于向量的导数：

- 定义： $x = (x_1, \dots, x_n)^T$ ， n 元函数 $g = g(x_1, \dots, x_n)$ ，则 $\frac{dg}{dx} = (\frac{\partial g}{\partial x_1}, \dots, \frac{\partial g}{\partial x_n})^T$ ，

$$\frac{dg}{dx^T} = (\frac{\partial g}{\partial x_1}, \dots, \frac{\partial g}{\partial x_n})$$

称上式为 g 关于 x 的梯度

- 向量映射关于向量的导数：

- 定义： $x = (x_1, \dots, x_n)^T$ ， $f(x) = (f_1(x), \dots, f_m(x))^T$ ，则

$$\frac{df(x)}{dx^T} = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & & \vdots \\ \vdots & & \ddots & \\ \frac{\partial f_m}{\partial x_1} & \dots & & \frac{\partial f_m}{\partial x_n} \end{pmatrix}$$

- 矩阵对矩阵求导：

■ 定义: $X = (x_{ij})_{m \times n}$, $F(X) = (f_{ij}(X))_{r \times s}$, 则 $\frac{dF}{dX} = \begin{pmatrix} \frac{\partial F}{\partial x_{11}} & \frac{\partial F}{\partial x_{12}} & \dots & \frac{\partial F}{\partial x_{1n}} \\ \frac{\partial F}{\partial x_{21}} & \frac{\partial F}{\partial x_{22}} & & \vdots \\ \vdots & & \ddots & \\ \frac{\partial F}{\partial x_{m1}} & \dots & & \frac{\partial F}{\partial x_{mn}} \end{pmatrix}$,

其中 $\frac{\partial F}{\partial x_{ij}} = \begin{pmatrix} \frac{\partial f_{11}}{\partial x_{ij}} & \frac{\partial f_{12}}{\partial x_{ij}} & \dots & \frac{\partial f_{1s}}{\partial x_{ij}} \\ \frac{\partial f_{21}}{\partial x_{ij}} & \frac{\partial f_{22}}{\partial x_{ij}} & & \vdots \\ \vdots & & \ddots & \\ \frac{\partial f_{r1}}{\partial x_{ij}} & \dots & & \frac{\partial f_{rs}}{\partial x_{ij}} \end{pmatrix}$

● 常用公式:

■ $\frac{dx^T}{dx} = \frac{dx}{dx^T} = I$

■ $\frac{dx^T c}{dx} = \frac{dc^T x}{dx} = c$

■ $\frac{dx^T Ay}{dx} = \frac{dx^T}{dx} Ay = Ay$

■ $\frac{dy^T Ax}{dx} = \frac{dx^T A^T y}{dx} = A^T y$

■ $\frac{dx^T A}{dx} = A$

■ $\frac{dx^T Ax}{dx} = (A + A^T)x$

● 行列式的导数:

■ $\frac{d|A|}{dA} = (A_{ij})_{n \times n} = A^{*T}$

■ $\frac{d|A^{-1}|}{dA} = \frac{-\frac{d|A|}{dA}}{|A|^2} = -\frac{A^{-T}}{|A|}$

- 迹的导数:

- $\frac{d}{dA} \text{tr}(AB^T) = \frac{d}{dA} \text{tr}(B^T A) = B$, 其中 $A_{m \times n}, B_{m \times n}$

- $\frac{d}{dA} \text{tr}(A) = I_n$

- $\frac{d}{dA} \text{tr}(A^T A) = \frac{d}{dA} \text{tr}(AA^T) = 2A$

- $\frac{d}{dA} \text{tr}(A^2) = 2A^T$

- $\frac{d}{dA} \text{tr}(ABA^T) = A(B + B^T)$

- $\frac{d}{dA} \text{tr}(A^T BA) = (B + B^T)A$

- $\frac{d}{dA} \text{tr}(BA^{-1}) = -(A^{-1}BA^{-1})^T$

- $\frac{d(x^T Ax)}{dA} = \frac{d\text{tr}(x^T Ax)}{dA} = \frac{d\text{tr}(Axx^T)}{dA} = xx^T$

- 矩阵直和: $A \oplus B = \begin{pmatrix} A & O \\ O & B \end{pmatrix}$

- Hadamard 积 $A * B$, $(A * B)_{ij} = a_{ij}b_{ij}$

- 右 Kronecker 积: $A_{m \times n}, B_{p \times q}$, $A \otimes B = (a_{ij}B)_{m \times n}$